

教育背景

华东师范大学

2023.09 – 2027.06

计算机科学拔尖班 · 本科

- 学业表现:** GPA **3.84/4.0**, 专业排名 **2/25**; 曾获**国家奖学金**、**校优秀学生奖学金**、**校优秀学生等荣誉**; TOEFL **106**, CET-6 **616**。
- 研究兴趣:** 聚焦可信智能体与多智能体协作、知识增强与长程推理、模型可靠性评测及高效推理系统; 关注复杂任务中的工具调用治理、执行轨迹审计与长期记忆机制。
- 核心课程:** 大语言模型 (荣誉课)、AI 基础、自然语言处理、计算机视觉、概率论与数理统计、高等数学、程序设计、操作系统、计算机网络、数据管理系统、编译原理 (均满绩)。

核心科研与实习经历

通用 Agent 协作架构与长期记忆增强研究

2026.04 – 2026.06

智能体系统 / 复旦微电子集团 (中央研究院) 实习生

关键词: Trusted Agent, Multi-agent Collaboration, Tool Governance, Long-term Memory, Honcho, Graph RAG

- 扩展 Clawith 多 Agent 协作关系建模能力, 基于现有 **Agent2AgentRelationship** 有向关系与 **relationships.md** 上下文注入机制, 将 peer/supervisor/assistant/collaborator 等协作标签抽象为可表达任务委派、协作、审核等角色关系图, 为多 Agent 任务流转、责任边界和协作上下文管理提供结构化建模基础。
- 设计关系感知的 Agent-to-Agent 任务交接机制, 将依赖自然语言 SystemMessage / Prompt 触发的交接方式改造为结构化 handoff envelope, 统一携带 task id、source / target agent、关系角色、上下文摘要和预期产出等字段, 提升跨 Agent 任务交接的上下文完整性与结果回传稳定性。
- 优化 Agent 自主运行场景下的工具权限治理机制, 基于 Agent 访问模式设计工具级权限策略, 在工具调用层增加硬权限拦截, 限制自主周期任务将 memory、workspace 等私有内容发布到公共渠道, 降低多 Agent 系统中的越权访问与隐私泄露风险。
- 设计 Agent 长期记忆与任务状态的分层管理规则, 区分长期偏好/经验、当前任务/待办事项与未来唤醒信息, 并在 Memory 写入链路中加入任务类内容识别与提示机制, 减少待办事项误写入长期记忆的问题, 提升多轮任务管理的可维护性。
- 接入并评测 Honcho 与 TencentDB Agent Memory 两类长期记忆方案, 围绕检索速度、召回质量、幻觉风险、跨用户/跨项目隔离和共享记忆能力设计 benchmark, 为企业多用户协作 Agent 的记忆架构选型提供实验依据。

面向长程交互可靠性的可控 LLM Agent 研究

2025.12 – 2026.01

大模型微调与智能体 / 项目负责人 / 学院项目评审获第 1 名

关键词: Controllable Agent, Dynamic RAG, Evidence Tracking, Long-context Reliability

- 面向连续对抗交互中目标漂移、论据遗忘与输出不一致问题, 构建**多轮辩论 Agent 原型**, 设计包含立场漂移检测、论据溯源与阶段化攻防策略的对抗流程。
- 构建约 **3 万条** 专项指令数据集, 覆盖立场保持、论证补强、反驳生成、证据引用与不确定性表达等任务类型; 设计三阶段 LoRA 微调策略, 提升模型在连续交互中的可控性与输出稳定性。
- 引入动态 RAG 与“**双轨记忆**”机制, 围绕当前对话状态与历史关键论据组织检索信息, 增强长程场景中的证据回溯能力与上下文连贯性。
- 在自建评测设置下, 将模型长程交互中的目标一致性维持在 **96%** 以上, 较基线提升 **45%**; 关键论据召回率达 **92%**, 长程对话幻觉率降低 **38%**。

基于扩散模型的两阶段后门样本净化与防御研究

2024.12 – 2025.03

可信人工智能 / 国家发明专利 (学生排名 2)

关键词: Diffusion Purification, Backdoor Defense, SSIM Localization, Patent

- 针对后门样本净化中防御效果与图像语义保真之间的权衡问题, 参与提出“**全局轻量净化 + 局部高强度修复**”的两阶段扩散去毒框架, 并完成实验验证与专利材料撰写。
- 主导设计基于 **SSIM 结构相似性** 的触发器定位算法, 对输入样本中的像素级可疑区域进行识别, 为局部差异化净化提供位置依据。
- 通过动态噪声步长分配策略, 对定位区域施加强净化、非可疑区域进行低扰动处理, 在抑制触发器影响的同时将单次净化计算开销降低约 **30%**。

- 在 CIFAR-10/GTSRB 等基准上将后门攻击成功率 (ASR) 从 90%+ 压制至 **6.15%** 以下, 同时保持分类准确率 $\geq 90\%$; 成果已申请**国家发明专利** (202511807335.9, 实质审查阶段)。

大语言模型系统构建 (Stanford CS336)

2025.09 – 2025.12

大模型训练 / A1 Leaderboard 排名 14/70

关键词: LLM Pretraining, FlashAttention, Parallelism, Data Filtering

- 独立实现 BPE 分词、Transformer Decoder、训练循环、采样生成与评估模块，完成从数据处理、模型预训练到推理评测的 LLM 系统闭环。
- 手写 FlashAttention-2 风格前向与反向传播，结合 Tiling、片上缓存复用与访存复杂度分析，理解长序列训练中 HBM 带宽瓶颈及算子优化路径。
- 复现 Megatron-LM 风格张量并行与 1F1B 流水线并行，掌握多卡训练中的参数切分、流水执行与通信调度机制。
- 构建 MinHash-LSH 文本去重与质量过滤流水线，完成训练语料预处理与质量控制；A1 Leaderboard 排名 14/70。

面向多模态生成与实时执行的具身绘画机器人系统

2025.04 – 2026.05

具身智能与实时系统 / 核心成员 / 国家级创新创业项目

关键词: Embodied System, SylixOS, EtherCAT, Diffusion, Robotic Arm

- 面向多模态生成结果在真实机器人执行环境中的落地需求，参与构建由图像生成、轨迹规划、实时通信与机械臂控制组成的具身绘画系统，打通从视觉内容到物理执行的完整链路。
- 负责 **EtherCAT** 工业协议栈在国产实时操作系统 **SylixOS** 上的移植与驱动适配，重构底层 IOCTL 命令集与网卡驱动，实现六轴机械臂控制过程中的稳定通信与设备交互。
- 结合 Diffusion 线稿生成与矢量轨迹规划，将生成结果转化为机械臂可执行的运动控制指令，并实现 **1ms** 周期硬实时通信控制。
- 项目获 2025 年全国大学生计算机系统能力大赛操作系统设计赛道**国家三等奖**，验证了多模态生成模块与国产实时控制系统协同执行的可行性。

腾讯云黑客松 · 第二届智能渗透挑战赛决赛

2026.04

安全 Agent / 成员 / 所在团队获全国第五

关键词: Security Agent, CTF Harness, Vulnerability Knowledge Base, Tool Use

- 于浙江大学、美国西北大学陈焰教授实验室实习，参与构建以 LLM 为核心的自主渗透 Agent Harness，面向隔离云靶场中的自动化众测、CVE/云安全漏洞、多层网络模拟与基础域渗透等阶梯式任务。
- 负责整理漏洞知识库、工具调用规范与结果校验流程，将漏洞识别、路径规划、错误路径排除和阶段性目标保持规则沉淀为可复用的执行知识。
- 围绕多阶段渗透任务的稳定执行参与迭代 Agent 工作流与验证机制；所在团队进入决赛并获**全国第五**。

面向垂直领域的 Agent-in-the-Loop 微调数据集自动化构建

2025.02

大模型数据工程 / 南洋理工大学 (NTU) 科研交流

关键词: Agent-in-the-Loop, Instruction Data Generation, Vertical-domain Fine-tuning, Data Quality Control

- 面向企业 BI / 数据分析软件场景中高质量微调数据稀缺的问题，构建 Agent-in-the-Loop 数据工程流程，将产品文档、使用教程、FAQ 与故障排查材料转化为可用于 instruction tuning 的结构化数据。
- 围绕产品问答、操作指导、故障排查和业务分析规划等 **4 类**典型用户任务，构建垂直领域微调数据体系，覆盖单轮问答、多步操作说明、错误诊断与场景化分析等数据类型。
- 设计由 Planner、Generator、Critic、Verifier 与 Refiner 组成的 **5 阶段**数据生成与质量控制流程，分别完成任务规划、样本生成、答案审查、证据校验和迭代改写。
- 为生成样本绑定原始文档证据，并结合规则过滤、LLM-as-a-Judge、相似度去重和质量评分等 **4 类**质量控制机制，减少低质量样本、重复样本与无依据幻觉内容。
- 构建面向企业 BI 产品使用、故障排查与业务分析场景的 SFT 数据集原型，支持按任务类型、证据来源、质量评分与错误类型进行数据筛选和评估。

🔧 技术能力与荣誉

研究能力	聚焦可信智能体、知识增强与长程推理、模型安全与可靠性评测；熟悉 RAG/Agent 架构、大模型训练推理及系统化实验设计，具备算法实现、实验验证与专利材料撰写经验。
工程能力	熟悉 Python / PyTorch / Transformers / PEFT / Docker / Linux；具备 LLM 训练框架、推理优化、自动化评测、数据清洗与可复现实验流水线搭建经验。
系统基础	具备操作系统、计算机网络、编译原理、数据库与并行计算基础；实践涉及 FlashAttention、张量并行、流水线并行、KV Cache 复用、RTOS 驱动适配与工业通信协议栈。
荣誉奖项	国家奖学金、校优秀学生奖学金、校优秀学生；全国大学生计算机系统能力大赛操作系统设计赛道国家三等奖；腾讯云智能渗透挑战赛决赛全国第五；Stanford CS336 A1 Leaderboard 14/70。
语言能力	TOEFL 106, CET-6 616；能够阅读英文论文、撰写技术文档并进行英文科研交流。