



教育背景

华东师范大学

2023.09 – 2027.06

计算机科学拔尖班 · 本科

- **学业表现:** GPA 3.84/4.0, 专业排名 2/25; 曾获国家奖学金、校优秀学生奖学金、校优秀学生等荣誉。
- **英语能力:** CET-4 657, CET-6 616, TOEFL 106。

核心科研与实习经历

面向企业级场景的多 Agent 协作与任务治理框架研究

2026.04 – 2026.06

智能体系统 / 复旦微电子集团 (中央研究院) 实习生

关键词: Multi-agent Collaboration, Agent-to-Agent Communication, Tool Governance, Long-term Memory, Honcho

- 面向企业级多用户协作场景, 设计通用 Agent-to-Agent 协作框架, 将用户/员工 Agent 之间的 supervisor、peer、assistant、collaborator 等关系抽象为有向关系图, 明确任务委派、协作、审核与结果回传边界。
- 将依赖自然语言提示的任务交接升级为结构化 **handoff envelope**, 统一封装 task id、source/target agent、关系角色、上下文摘要、预期产出、约束条件与完成标准, 提升跨 Agent 任务流转的可追踪性与上下文完整性。
- 构建关系感知的异步 Agent 协作机制, 支持 lead agent 基于任务动态选择协作对象, 通过 inbox/outbox 接收子任务 evidence packet、partial callback 与 reviewer feedback, 并在结果合成阶段保留证据来源与未解决缺口。
- 优化自主 Agent 的工具权限治理机制, 在工具调用层加入权限拦截与访问模式检查, 限制子 Agent 或周期任务将 memory、workspace 等私有内容发布到公共渠道, 降低多 Agent 系统中的越权访问和隐私泄露风险。
- 基于 DDR-Benchmark 10-K 任务构建 ReAct、原始 Hermes 与 A2A 协作系统的对照评测流程, 使用 message-wise accuracy、trajectory/chat-wise accuracy、insufficient rate、incorrect rate 等指标分析协作效果; A2A 达到 **76.48% message-wise accuracy** 与 **53.66% trajectory/chat-wise accuracy**, 验证了多 Agent 任务拆解、证据回传与结果合成机制的有效性。

DialecticFlow: 面向长程交互可靠性的可控辩论 LLM Agent

2025.12 – 2026.01

大模型微调与智能体

关键词: Qwen2.5-7B, LLaMA-Factory, LoRA, Stance-aware RAG, Dual-track Memory

- 面向华语辩论中立场漂移、质询失效、证据方向错误、轮次错配与预算失控等问题, 将辩论生成建模为带有显式约束、可诊断状态与可恢复错误处理的长流程策略控制任务, 构建基于 **Qwen2.5-7B** 的可控辩论 Agent **DialecticFlow**。
- 构建三阶段专项指令数据管线, 包含 **17,984** 条结构学习样本、**4,992** 条真实辩手风格样本与 **6,268** 条对抗鲁棒性样本; 基于 **LLaMA-Factory** 顺序训练 LoRA adapter, 强化辩论结构、表达密度与诱导场景下的规则鲁棒性。
- 设计 **双轨记忆机制** 与 **立场感知 RAG** 知识库, 将本方论证链、对方论证链及承诺分离维护, 并为定义、判准、事实政策、典型案例等材料标注 stance polarity 与 usable round, 实现按轮次动态路由由上下文与证据方向过滤。
- 引入 **生成后检查与诊断式重写** 机制, 对候选输出检查立场一致性、相关性、质询形式、证据风险与 token 预算, 并在检测到开放式质询、无来源数字或轻微立场漂移时触发局部重写, 提升生成流程的可观测性与可恢复性。
- 参考华语辩论评审维度设计内部消融评测, 比较 Prompt-only、SFT-only、+Dual、+RAG 与 Full 五个版本; 完整系统归一化平均分由 **29.5** 提升至 **94.0**, 在立论逻辑、反驳精准度、立场一致性、结辩质量与 AI 合规性五项维度上分别达到 **94.2 / 94.6 / 93.8 / 94.0 / 93.2**。

大模型智能体与数据智能研究实习

2026.06 – 至今

上海人工智能实验室 Research Intern

关键词: Data Agent, Agentic RL, LLM Agent Memory, Long-horizon Reasoning

- 围绕 **DataElf** 数据智能体方向, 研究自然语言数据分析任务到可执行分析流程的自动化转化机制, 探索基于大模型 Agent 的任务理解、数据查询、工具调用、结果验证与自动化洞察生成流程。
- 面向长程任务中的智能体自主决策问题, 开展 **Agentic RL** 与 **Agent Memory** 方向研究, 探索基于 Controller Model 的 LLM/VLM Agent 协同框架, 通过策略学习优化模型调用、任务规划与长期交互中的自我改进能力。

Rewriting the Vision-Language Bridge: 面向多模态大模型连接器的快速闭式后门编辑

2026.04 – 至今

可信人工智能安全 / 第一作者论文在研

关键词: MLLM Backdoor, Closed-Form Model Editing, Stealthy Visual Triggers, Leakage Suppression

- 提出一种无需训练的闭式视觉连接器编辑方法, 将多模态大模型后门编辑建模为连接器映射空间中的受约束线性重写问题, 实现低成本、可控的定向语义诱导。
- 设计角落残片式、边缘裁切式等隐蔽视觉触发器, 并构建基于投影特征可分性的快速筛选流程, 在定向诱导强度、视

觉隐蔽性与误触发风险之间取得平衡。

- 引入基于 Fisher 判别准则的列级门控策略，根据触发样本与干净样本在连接器中间隐层维度上的可分性，对闭式编辑得到的权重更新进行软门控，保留触发相关更新方向并抑制语义泄漏，将误触发率从约 **37%** 降低至约 **18%**。
- 在 LLaVA-v1.5-7B 等开源多模态大模型上验证方法有效性，仅使用少量干净背景样本即可达到约 **92%** 的定向诱导成功率，并保持约 **85%** 的干净样本准确率。

基于扩散模型的两阶段后门样本净化与防御研究

2024.12 – 2025.03

可信人工智能 / 国家发明专利（学生第二完成人）

关键词：Diffusion Purification, Backdoor Defense, SSIM Localization, Patent

- 面向黑盒图像分类场景下的后门防御问题，参与构建输入侧样本净化框架，在不访问模型参数、梯度和训练数据的条件下，对待分类样本进行推理前去毒处理。
- 参与设计两阶段扩散净化流程：第一阶段对整张图像施加轻量级 DDPM 前向扰动，并通过反向去噪恢复主体语义，用于破坏低可见性、低鲁棒性的隐蔽触发器。
- 参与实现基于 **SSIM 结构相似性差异** 的触发器定位方法，通过比较原始样本与第一阶段净化样本的像素级结构差异，生成可疑区域热图，定位高可见性触发器区域。
- 参与设计局部差异化净化策略，根据可疑区域强度动态分配像素级噪声步长，对触发器区域施加强扰动与选择性去噪，对非可疑区域保持低扰动，以平衡后门抑制与图像语义保真。
- 在 CIFAR-10/GTSRB 等基准上将后门攻击成功率（ASR）从 90%+ 压制至 **6.15%** 以下，同时保持分类准确率 $\geq 90%$ ；成果已申请**国家发明专利**（202511807335.9，实质审查阶段）。

其他项目经历

面向多模态生成与实时执行的具身绘画机器人系统

2025.04 – 2026.05

具身智能与实时系统 / 核心成员 / 国家级创新创业项目（结题优秀）

关键词：Embodied System, SylixOS, EtherCAT, Diffusion, Robotic Arm

- 面向多模态生成结果在真实机器人执行环境中的落地需求，参与构建由图像生成、轨迹规划、实时通信与机械臂控制组成的具身绘画系统，打通从视觉内容到物理执行的完整链路。
- 负责 **EtherCAT** 工业协议栈在国产实时操作系统 **SylixOS** 上的移植与驱动适配，重构底层 IOCTL 命令集与网卡驱动，实现六轴机械臂控制过程中的稳定通信与设备交互。
- 参与图像到笔画链路优化，结合 Matting、QMUPD 与 Virtual Sketching 将人物图像转化为结构清晰、顺序可控的矢量笔画序列，提升线稿质量与路径连续性。
- 结合坐标映射、轨迹规划、逆运动学与 S 型速度规划，将二维笔画序列转化为机械臂可执行轨迹，并验证 **1 ms 周期** EtherCAT 通信链路下的伺服控制、状态回读与轨迹执行效果。
- 项目获 2025 年全国大学生计算机系统能力大赛操作系统设计赛道**国家三等奖**，验证了多模态生成模块与国产实时控制系统协同执行的可行性。

AgentDoG-Lite: 面向智能体安全诊断的大模型对齐研究

2026.07

大语言模型安全与对齐 / 个人研究项目

关键词：LLM Alignment, Agent Safety, LoRA SFT, DPO

- 面向大语言模型智能体安全风险识别问题，基于 **Qwen3.5-0.8B** 构建 Agent 安全诊断模型；采用 **LoRA** 参数高效微调，通过结构化安全数据进行 SFT，提升模型安全行为判别能力。
- 针对 SFT 后模型的安全偏好不足与误报问题，引入 **DPO** 进行偏好对齐，设计 **SFT+DPO** 两阶段训练策略优化决策边界，并在 Agent 安全基准上评估模型性能。

大语言模型系统构建（Stanford CS336）

2025.09 – 2025.12

大模型训练 / Assignment1 Stanford Global Leaderboard 排名 **14/70**

关键词：LLM Pretraining, FlashAttention, Parallelism, Data Filtering

- 实现 BPE 分词、Transformer Decoder、训练循环、采样生成与评估模块，完成从数据处理、模型预训练到推理评测的 LLM 系统闭环。
- 手写 FlashAttention-2 风格前向与反向传播，结合 Tiling、片上缓存复用与访存复杂度分析，理解长序列训练中 HBM 带宽瓶颈及算子优化路径。
- 复现 Megatron-LM 风格张量并行与 1F1B 流水线并行，掌握多卡训练中的参数切分、流水执行与通信调度机制。
- 构建 MinHash-LSH 文本去重与质量过滤流水线，完成训练语料预处理与质量控制；A1 Leaderboard 排名 **14/70**。